APRENDIZAJE POR REFUERZO

Índice

- Introducción
- Aprendizaje Q
- Ambiente no-determinista
- Diferencia Temporal
- Representación / Generalización

Introducción

- La tarea consiste en aprender una estrategia de comportamiento para un agente de forma de realizar un objetivo dado

- Se considera que:
  - El agente se encuentra en un estado **s**, que puede sensar de alguna forma.
  - El agente puede elegir realizar una acción **a** en ese estado.
  - Su acción provoca un cambio en el mundo (un nuevo estado).
  - El comportamiento es calificado con una recompensa **r**.

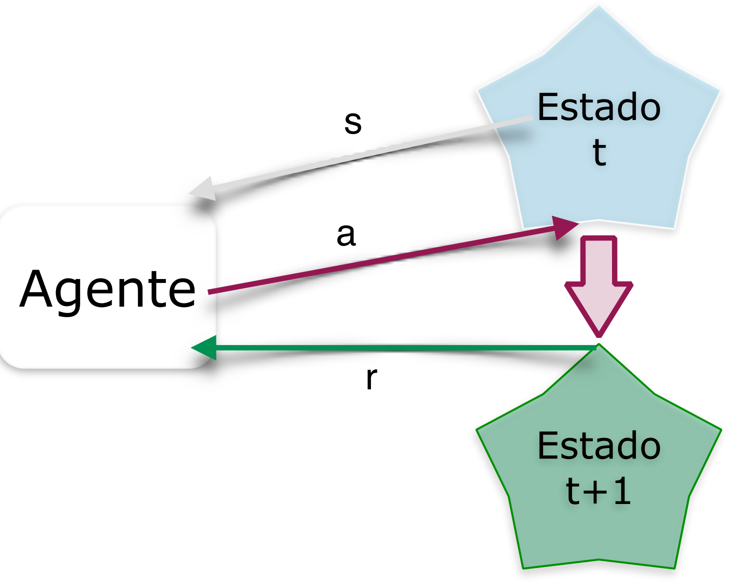

Introducción

- Por ejemplo:
  - Un jugador de damas.
  - Un robot que tiene que cargar su batería.
  - Un conjunto de robots que deben seguir cierta formación.
  - Cadena de producción.
  - ...
- Hay que considerar que:
  - No siempre una misma acción conduce a un mismo estado.
  - No siempre se tiene una “recompensa” inmediata a una acción.
  - ¿Cómo se distribuye la recompensa en toda la cadena de acciones?

Introducción

- Se considera entonces:
  - Un conjunto de estados S
  - Un conjunto de acciones A
  - Un comportamiento a aprender $\pi: S \rightarrow A$
- Diferencias con otros problemas:
  - Demora en la recompensa: no contamos con un conjunto de instancias $<s, \pi(s)>$ para aprender.
  - Exploración vs. explotación: ¿cómo se balancea la búsqueda de nuevos datos con la obtención recompensas a partir de lo ya aprendido?
  - Observación parcial de los estados.
  - Aprovechamiento de la información ya recolectada.

Introducción

- Escenarios posibles:
  - ¿Son las acciones del agente deterministas?
  - ¿Puede el agente predecir el resultado de su acción?
  - ¿Se cuenta con un experto que enseñe?
  - ¿Se puede elegir la secuencia de entrenamiento?
- Consideremos procesos de decisión de Markov (MDPs):
  - El tiempo es discreto.
  - El agente selecciona una acción a_t en estado s_t
  - El ambiente retorna una recompensa $r_t=r(s_t,a_t)$ y el siguiente estado $s_{t+1}=\delta(s_t,a_t)$. El agente desconoce estas funciones.
  - Nada depende de la secuencia de acciones previas al estado s_t.

Introducción

- Buscamos una secuencia de acciones π que maximice el retorno acumulado con descuento:

$$V_\pi(s_t) = r_t + \gamma . r_{t+1} + \gamma^2 . r_{t+2} + \ldots = \Sigma_i \gamma^i . r_{t+i}$$

donde $0 \leq \gamma < 1$ pondera el retorno inmediato vs. el futuro

- La estrategia óptima π^* será aquella que maximiza el retorno:

$$\pi^*(s) = \mathrm{argmax}_\pi V_\pi(s), \quad (\forall s)$$

$$V^*(s) = V_{\pi^*}(s)$$

- Otras posibles V:
  - horizonte finito: $\Sigma_i^h \gamma^i r_{t+i}$
  - recompensa media: $\lim_{h \to \infty} h^{-1} \Sigma_i^h \gamma^i r_{t+i}$

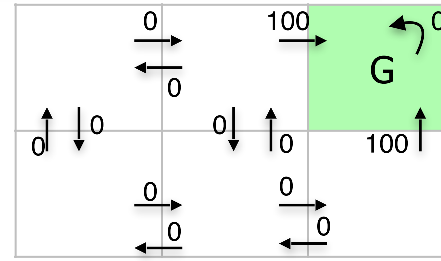

r(s,a)

con γ=0,9 :

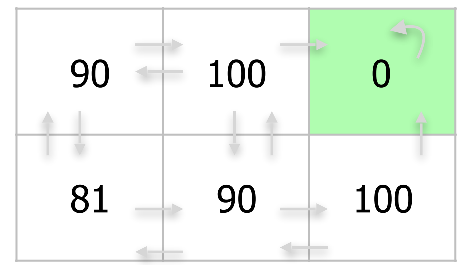

V*(s)

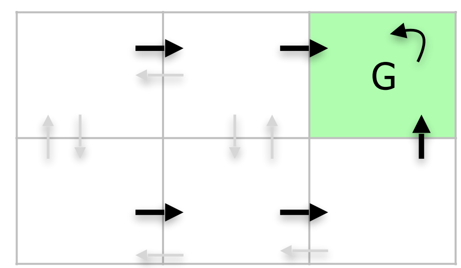

π*(s)

Aprendizaje Q

- ¿Cómo obtenemos π^*?
  - Intentamos aprender V^*.
  - Luego, la acción a tomar es la que lleva al siguiente estado que maximiza la recompensa:

$$\pi^*(s) = \text{argmax}_a [\ r(s,a) + \gamma V^*(\delta(s,a))\ ]$$

    - Se requiere conocer r y δ.
    - ¿Qué sucede cuando no se cuenta con información perfecta?

Aprendizaje Q

- Utilizamos otra función de evaluación:

$$Q(s,a) = r(s,a) + \gamma V^*(\delta(s,a))$$

- La acción a tomar es :

$$\pi^*(s) = \text{argmax}_a\, Q(s,a)$$

- Esto es simplemente una reescritura, pero si logro aproximar Q, no preciso conocer directamente a r ni a δ.
- Para aproximarla tomamos en cuenta la definición de V*:

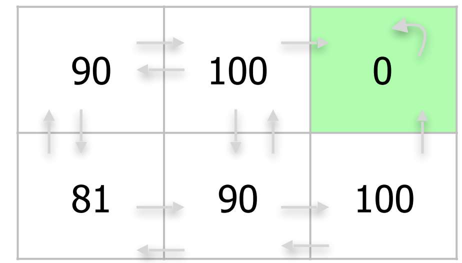

V*(s)

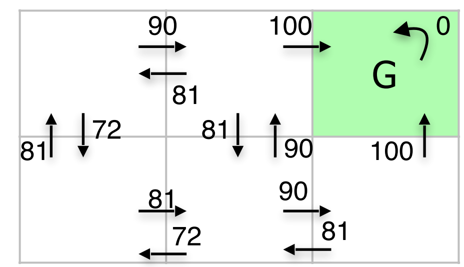

Q(s,a)

$$\left.\begin{aligned} V^*(s) &= \max_a Q(s,a) \\ Q(s,a) &= r(s,a) + \gamma V^*(\delta(s,a)) \end{aligned}\right\} Q(s,a) = r(s,a) + \gamma \max_{a_2} Q(\delta(s,a),a_2)$$

Aprendizaje Q

- Estimamos la función Q:

$$Q^*(s,a) \leftarrow r(s,a) + \gamma \max_{a_2} Q^*(s',a_2)$$

  - Inicializo la tabla con valores nulos.
  - Elijo una acción.
  - Veo el resultado: r y s'.
  - Actualizo Q*(s,a).

- Observar que en el ejemplo:
  - En la primer corrida no se actualiza ninguna entrada hasta llegar a G.
  - En cada corrida los valores se propagan hacia atrás a medida que Q* se actualiza.

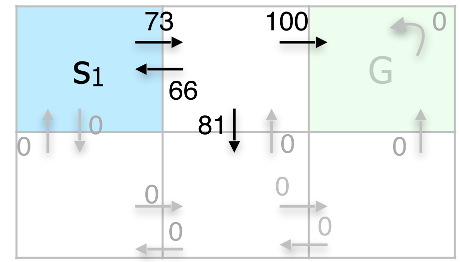

derecha Q*(s,a) en t

$Q^*(s_1, \text{derecha}) \leftarrow$
$0 + 0{,}9 \max(\{66,81,100\})$

$Q^*(s_1, \text{derecha}) \leftarrow 90$

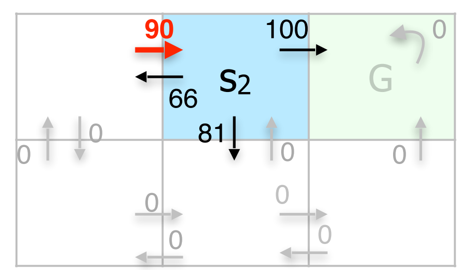

Q*(s,a) en t+1

Aprendizaje Q

- Convergencia: Sea un MDP determinista con recompensa acotada. La tabla de Q^* se inicializa con valores aleatorios. Si el agente visita todo estado-acción infinitas veces, Q^* converge a Q.

- Elección de la acción:
  - Lo razonable sería elegir siempre la de mayor recompensa estimada. (explotación)
  - Pero se pueden perder otras mejores, además de no cumplir la visita “infinita” a todos los pares (s, a). (exploración)
  - Se puede establecer una política de exploración aleatoria, por ejemplo, ponderada por lo ya conocido...

$$P(a_i \mid s) = k^{Q^*(s,a_i)} / \sum_j k^{Q^*(s,a_j)}$$

Aprendizaje Q

- ¿Cómo agilitar el aprendizaje?:
  - Podemos repetir un mismo episodio (en memoria) las veces que queramos...
  - Actualizar la secuencia en orden inverso a su ejecución.
  - Recolectar los <s,a,r> y reentrenar periódicamente con estos valores.

Ambiente no-determinista

- ¿Qué sucede cuando acciones y recompensas no son deterministas?
- Generalizamos el algoritmo de aprendizaje Q:

$$V(s_t)= E(\Sigma_i \gamma_i r_{t+i})$$

$$Q(s,a) = E(r(s,a) + \gamma V^*(\delta(s,a)))= E(r(s,a)) +\gamma E(V^*(\delta(s,a))$$

$$=E(r(s,a)) +\gamma \Sigma_{s'} P(s'|s,a) V^*(s')$$

$$=E(r(s,a)) +\gamma \Sigma_{s'} P(s'|s,a) \max_{a'} Q(s',a')$$

- Como r no es determinista, la anterior regla de aprendizaje no converge; utilizamos entonces la siguiente regla:

$$Q^*_n(s,a) \leftarrow (1-\alpha_n) Q^*_{n-1}(s,a) + \alpha_n [r+\gamma \max_{a2} Q^*_{n-1}(s',a_2)]$$

donde α_n suaviza la tasa de aprendizaje, por ejemplo:

$$\alpha_n= (1+visitas(s,a))^{-1}$$

Ambiente no-determinista

- Convergencia:

  (H) Sea un MDP no determinista con recompensa acotada, y $\alpha_n(i,s,a)$ la iteración correspondiente a la i-ésima vez que la acción a se aplica en s.

  Si todo par estado-acción se visita una cantidad infinita de veces y:

$$\Sigma_i^\infty \alpha_n(i,s,a)=\infty \qquad \Sigma_i^\infty [\alpha_n(i,s,a)]^2< \infty$$

  (T) Q^* converge a Q

Aprendizaje TD

- El algoritmo Q es un caso particular de aprendizaje por diferencia temporal.
- Estos algoritmos reducen la diferencia de estimación que hace un agente con el paso del tiempo:

$Q^{(1)}(s_t,a_t) \leftarrow r_t + \gamma \max_a Q^*(s_{t+1},a)$ miro 1 paso delante

$Q^{(2)}(s_t,a_t) \leftarrow r_t+\gamma\, r_{t+1}+\gamma^2 \max_a Q^*(s_{t+2},a)$ miro 2 pasos

...

$Q^{(n)}(s_t,a_t) \leftarrow r_t+ \gamma\, r_{t+1}+ \gamma^2 r_{t+2}+ \ldots + \gamma^{n-1} r_{t+n-1} + \gamma^n \max_a Q^*(s_{t+n},a)$ miro n pasos

- Todas esas fórmulas a su vez se pueden combinar en una:

$$Q^{\lambda}(s_t,a_t) = (1-\lambda)\, [Q^{(1)}(s_t,a_t) + \lambda Q^{(2)}(s_{t+1},a_{t+1}) + \ldots]$$

$$Q^{\lambda}(s_t,a_t) \leftarrow r_t + \gamma\, [(1-\lambda) \max_a Q^*(s_{t+1},a) + \lambda Q^{\lambda}(s_{t+1},a_{t+1})]$$

- Cuanto mayor es el valor de λ, más pesan los valores más alejados.

Representación de Q

- No siempre se puede tener una tabla para representar Q.
- Además, se puede intentar generalizar Q a partir de los ejemplos vistos.
- La función, entonces, se puede representar con una función lineal, una red neuronal, etc.
- Problema: la convergencia de Q^* a Q no está garantizada.

Representación de Q

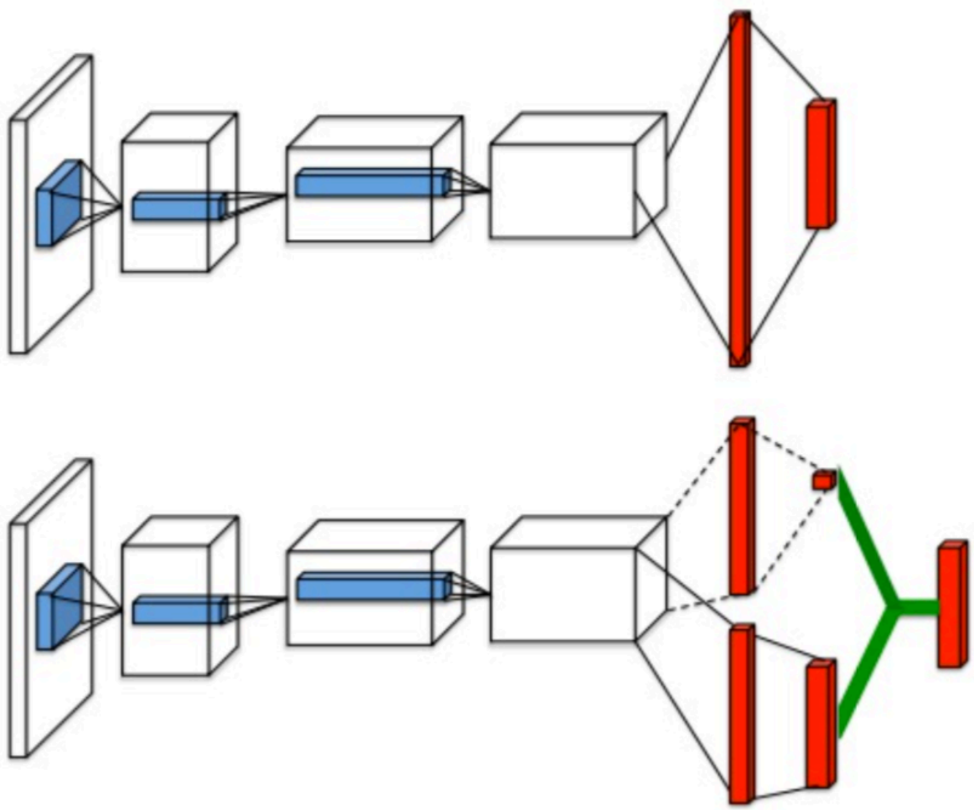

Figura 2.12: Arriba: Q-network estándar [29] con una única secuencia. Abajo: *Dueling* Q-*network*. Esta red tiene dos secuencias para estimar separadamente el escalar $V(s)$ y la ventaja para cada acción. Tomada del trabajo de van Hasselt [43].

Representación de Q

Refuerzos y una vida de juegos :)

- 1963 - Ta-Te-Ti (Menace)
- 1992 - Backgammon (TD-Backgammon)
- 2016-2017 - Go (AlphaGo - AlphaGo Zero)
- 2018 - Ajedrez, Shogi y Go (AlphaZero)

Resumiendo...

- El aprendizaje por refuerzo permite aprender estrategias para agentes “autónomos”. En particular, vimos el problema sobre MDP.
- El algoritmo Q permite aproximar el retorno, sin saber cuál es la función r.
- Bajo ciertas condiciones el algoritmo Q converge.
- El algoritmo Q es un caso particular de un algoritmo TD